

Tugas 4

No. 1: Preprocessing Teks

Topik: Tokenisasi, Stopwords Removal, dan Stemming

Tujuan

Mahasiswa mampu mengimplementasikan pipeline preprocessing teks Bahasa Indonesia secara lengkap dan menganalisis dampaknya terhadap kualitas data.

Studi Kasus

Anda bekerja di bagian pengembangan sistem pencarian dokumen internal Fakultas Teknik UNM. Saat ini terdapat kumpulan berita dan pengumuman resmi yang masih kotor (mengandung tanda baca, huruf kapital, stopwords, dan kata berimbuhan). Anda diminta membersihkan data tersebut agar siap digunakan untuk sistem temu kembali informasi.

Dataset

Gunakan minimal **5 dokumen** berbahasa Indonesia (boleh diambil dari berita online, pengumuman kampus, atau Anda buat sendiri). Contoh tema: teknologi, komputer, atau pendidikan.

Tugas yang Harus Dikerjakan

1. Buat fungsi Python bernama `preprocess_text(text)` yang melakukan urutan berikut:
 - Case folding
 - Cleaning (menghapus angka, tanda baca, dan karakter khusus)
 - Tokenisasi
 - Stopwords removal (gunakan Sastrawi)
 - Stemming (gunakan Sastrawi)
2. Terapkan fungsi tersebut pada ke-5 dokumen.
3. Tampilkan perbandingan **sebelum** dan **sesudah** preprocessing untuk setiap dokumen (minimal 2 dokumen ditampilkan secara lengkap).
4. Hitung dan tampilkan:
 - Jumlah token sebelum preprocessing
 - Jumlah token setelah preprocessing
 - Persentase pengurangan token
5. Analisis singkat (maksimal 1 paragraf): Apa dampak preprocessing terhadap kualitas data untuk keperluan sistem IR?

Deliverable

- File Jupyter Notebook (.ipynb) atau script Python (.py)

- Kode harus dapat dijalankan tanpa error
- Output yang jelas dan rapi
- Analisis singkat di bagian akhir

Library yang Diizinkan

re, Sastrawi, dan library standar Python.

No. 2: Pembobotan (Term Weighting)

Topik: Bag-of-Words, TF, IDF, dan TF-IDF

Tujuan

Mahasiswa mampu menghitung dan mengimplementasikan pembobotan TF-IDF baik secara manual maupun menggunakan library, serta memahami makna bobot yang dihasilkan.

Studi Kasus

Anda diminta membangun prototipe sederhana sistem pencarian dokumen teknis untuk mahasiswa Teknik Komputer. Terdapat beberapa dokumen singkat mengenai topik komputer dan teknologi. Anda harus mengubah dokumen-dokumen tersebut menjadi representasi numerik menggunakan TF-IDF agar nantinya dapat digunakan untuk perhitungan kemiripan (cosine similarity).

Dataset

Gunakan minimal **4 dokumen** pendek berbahasa Indonesia (masing-masing 1–3 kalimat). Contoh tema: sistem komputer, jaringan, kecerdasan buatan, atau sistem temu kembali.

Tugas yang Harus Dikerjakan

1. Lakukan preprocessing sederhana terlebih dahulu (minimal case folding + tokenisasi + stopwords removal).
2. Bangun representasi **Bag-of-Words** (raw count) dari ke-4 dokumen.
3. Hitung secara **manual** (ditulis di notebook atau ditampilkan dengan jelas):
 - Term Frequency (TF) untuk setiap term di setiap dokumen
 - Document Frequency (df) dan Inverse Document Frequency (IDF)
 - Nilai TF-IDF untuk setiap term di setiap dokumen
4. Implementasikan perhitungan TF-IDF menggunakan **scikit-learn** (TfidfVectorizer) dan bandingkan hasilnya dengan perhitungan manual.
5. Tampilkan matriks TF-IDF (baik manual maupun dari scikit-learn).
6. Analisis singkat: Term manakah yang memiliki bobot TF-IDF tertinggi pada masing-masing dokumen? Mengapa term tersebut penting?

Deliverable

- File Jupyter Notebook (.ipynb) atau script Python (.py)
- Perhitungan manual harus terlihat jelas (boleh menggunakan tabel pandas)
- Hasil scikit-learn harus ditampilkan
- Analisis singkat di bagian akhir

Library yang Diizinkan

re, Sastrawi (opsional), scikit-learn, pandas, dan library standar Python.

Ketentuan Umum Penugasan

- Dikerjakan secara individu.
- Kode harus rapi, diberi komentar, dan mudah dibaca.
- Plagiarisme akan mendapatkan nilai nol.
- Format nama file: NIM_Nama_Preprocessing.ipynb dan NIM_Nama_TFIDF.ipynb.